

## **8273001051 - Büyük Dil Modelleri Dersi – FİNAL TESLİMATI—SLM Fine-Tuning: Uygulama, Sonuçlar ve Sunum (Son Teslim tarihi: 31 Mayıs 2026)**

Hazırlayan: Emrah Aksu

Öğrenci No: 258273001032

Ders: 8273001051 - Büyük Dil Modelleri (Bahar Dönemi)

Dersimizin Öğretim Üyesi: Dr.Öğr.Üyesi ALİ ÇETİNKAYA

Bilgisayar Mühendisliği YL

**Proje Konusu: Türkçe Hukuki Metinlerin Küçük Dil Modelleri (SML) İle Özetlenmesi Ve Performans Analizi**

### **1. GİRİŞ VE LİTERATÜR TARAMASI**

#### **1.1. Problem Tanımı ve Motivasyon**

Günümüzde bilgi toplumunun ve dijitalleşmenin hız kazanmasıyla birlikte, hukuki süreçlerde üretilen dokümantasyonun hacmi ve yapısal karmaşıklığı devasa boyutlara ulaşmıştır. Özellikle Yargıtay ilamları, Danıştay kararları ve Resmi Gazete metinleri gibi birincil hukuki kaynaklar; yoğun bir terminoloji (arkaik hukuk dili), iç içe geçmiş atıf zincirleri ve uzun paragraf yapıları barındırmaktadır. Bu durum, hukuk profesyonellerinin (hakim, savcı, avukat) karar alma ve içtihat tarama süreçlerinde ciddi bir zaman kaybına yol açtığı gibi, sıradan vatandaşların adalete ve hukuki bilgiye erişimini de zorlaştırmaktadır.

Bu çalışmanın temel motivasyonu; milyarlarca parametreye sahip ve çalıştırılması için yüksek kaynaklı bulut sunucularına (GPU cluster) ihtiyaç duyan devasa Büyük Dil Modelleri (LLM) yerine, daha düşük kaynak tüketen, yerel cihazlarda (örneğin uç birim mimarilerinde veya standart dizüstü bilgisayarlarda) gizlilik esasına uygun olarak çalıştırılabilen Küçük Dil Modellerinin (SML - Small Language Models) Türkçe hukuk dikeyindeki limitlerini ve özetleme performanslarını test etmektir. Bu doğrultuda, uzun ve karmaşık hukuki metinlerin, çekirdek anlamını ve hukuki gerekçesini kaybetmeden 3-5 cümlelik yapılandırılmış özetlere dönüştürülmesi hedeflenmektedir. Proje kapsamında üretilen sonuçların, Türkçe Hukuk Doğal Dil İşleme (Legal NLP) literatüründeki açık kaynaklı model ve kaynak kıtlığını gidermeye katkı sunması amaçlanmaktadır.

#### **1.2. Yöntemsel Gelişmeler ve Veri Seti Entegrasyonu**

Projenin vize aşamasında, Hugging Face Hub üzerinde yer alan Turkish-NLI/legal\_nli\_TR\_V1 veri seti doğrudan sisteme dahil edilmiş ancak bu veri setinin mimari yapısı gereği bir Doğal Dil Çıkarımı (NLI - Natural Language Inference) görevi için tasarlandığı ve ham haliyle metin özetleme (Abstractive/Extractive Summarization) görevine doğrudan hizmet edemediği saptanmıştır. Hocamızın akademik geri bildirimleri ve yönlendirmeleri doğrultusunda, final aşamasında bu yöntemsel eksiklik tamamen giderilmiştir. Proje kapsamında, ham metinlerin (premise) içerisindeki gürültüleri ayıklayan ve metnin yapısal anatomisini çözümleyen gelişmiş bir "**Regex Extraction Pipeline**" (**Kural Tabanlı Ayıklama Hattı**) sıfırdan inşa edilmiştir.

Geliştirilen bu boru hattı; metinlerdeki kurumsal kalıpları (T.C. Yargıtay, Esas/Karar No vb.) temizledikten sonra, metin içerisinde geçen ÖZET:, İÇTİHAT: ve GEREKÇE: gibi kritik anlamsal blokları regex (düzenli ifadeler) örüntüleriyle dinamik olarak yakalamaktadır. Ayıklanan bu kısımlar "Hedef Özet (Target Summary)", metnin geri kalan gövdesi ise "Girdi Metni (Input Text)" olarak etiketlenerek tam anlamıyla denetimli bir metin özetleme (supervised summarization) veri seti formatına dönüştürülmüştür. Donanım kısıtları ve kararlı eğitim dengesi gözetilerek, context sınırları 1.500 ile 3.000 token (yaklaşık 1100 - 2300 kelime) arasında olan yüksek kaliteli hukuk metin-özet çiftleri süzülerek nihai eğitim matrisi elde edilmiştir.

### 1.3. Literatür Taraması

Hukuk alanında Doğal Dil İşleme (Legal NLP) çalışmaları, dilin kendine has muhafazakar ve teknik yapısı nedeniyle genel amaçlı NLP modellerine kıyasla her zaman daha spesifik yaklaşımlar gerektirmiştir. Alan yazındaki temel çalışmalar ve projemize dayanak oluşturan literatür özeti aşağıda sunulmuştur:

1. **Vaswani ve ark. (2017) - "Attention Is All You Need":** Dikkat mekanizmasını (Attention Mechanism) temel alan Transformer mimarisini literatüre kazandırarak günümüzdeki tüm Küçük ve Büyük Dil Modellerinin mimari temelini atmıştır. Bu çalışmadaki sekans dizilim başarısı, hukuki metinlerdeki uzun menzilli bağımlılıkların (long-range dependencies) çözülmesini olanaklı kılmıştır.
2. **Chalkidis ve ark. (2020) - "LEGAL-BERT":** Avrupa Birliği mevzuatları ve mahkeme kararları üzerinde BERT mimarisini özelleştirerek, hukuki dikeyde eğitilen modellerin genel amaçlı modellere göre (domain-specific tuning) anlamlandırma ve sınıflandırma görevlerinde çok daha üstün performans gösterdiğini kanıtlamıştır.
3. **Zhong ve ark. (2020) - "Legal Text Summarization":** Hukuki metinlerin özetlenmesinde kararın rasyonel gerekçesinin (ratio decidendi) korunmasının önemini vurgulamış, klasik özetleme metriklerinin (ROUGE) yanı sıra anlamsal (semantik) doğruluğun ölçülmesi gerektiğini savunmuştur.
4. **Schwab ve ark. (2023) - "Parameter-Efficient Fine-Tuning in Legal NLP":** Kısıtlı donanım kaynaklarına sahip yerel sistemlerde LoRA (Low-Rank Adaptation) ve QLoRA yöntemlerinin, büyük modelleri tam parametre eğitmek yerine çok daha az kaynakla benzer doğrulukta sonuçlar üretebildiğini deneysel olarak göstermiştir.
5. **Türkçe Legal NLP Çalışmaları:** Türkiye'deki akademik yazında, Türkçe dilinin morfolojik zenginliği (sondan eklemeli yapısı) ve hukuk dilindeki Osmanlıca/Arapça kökenli ağır terminoloji nedeniyle çalışmalar görece kısıtlı kalmıştır. Yapılan güncel çalışmalarda (örn. yerel mahkeme kararlarının sınıflandırılması ve analizine yönelik çalışmalar), Türkçe için geliştirilen BERT ve LLM türevlerinin veri temizliği (preprocessing) kalitesine doğrudan bağlı olduğu raporlanmıştır. Vize raporunda referans gösterilen bazı öncül öğrenci/çalışma grubu projeleri (Keziban Karagümüş, 2026), hakemli akademik yayın standartları gereği literatür kısmından ayrıştırılarak projenin manuel doğrulama ve koordinasyon safhasına dahil edilmiştir.

## 2. METOT VE TEKNİK ALTYAPI

Bu çalışmada, Türkçe hukuki metinlerin özetlenmesi amacıyla Parameter-Efficient Fine-Tuning (Parametre Açısından Verimli İnce Ayar) yaklaşımlarından **QLoRA (Quantized Low-Rank Adaptation)** mimarisi kullanılmıştır. Donanım kısıtları (RTX 3050 4GB VRAM / Colab T4 GPU) ve yerel çalıştırılabilirlik kriterleri doğrultusunda, parametre boyutları 360M ile 2B arasında değişen üç farklı Küçük Dil Modeli (SML) seçilmiş ve optimize edilmiştir.

### 2.1. Seçilen Küçük Dil Modelleri (SML) ve Mimarileri

Proje kapsamında dikey performans analizi gerçekleştirmek üzere yapılandırılan model kartları şu şekildedir:

- **SmolLM2-360M-Instruct:** 360 milyon parametreye sahip, ultra hafif ve uç birimlerde (mobil/yerel) çalışmaya uygun bir modeldir. Hafif mimarisinin ağır hukuk dilindeki anlamsal sıkıştırma yeteneği test edilmiştir.
- **Qwen2.5-1.5B-Instruct:** Alibaba tarafından geliştirilen, özellikle kodlama ve mantıksal akıl yürütme becerileri yüksek, 1.5 milyar parametrelili bir modeldir. Türkçe dil desteği ve bağlam (context) yönetimi açısından güçlü bir adaydır.
- **Gemma-2-2B-It:** Google'ın açık kaynaklı, 2 milyar parametrelili gelişmiş mimarisidir. Attention mekanizmasındaki yenilikler sayesinde uzun metinlerdeki korelasyonları yakalamada yüksek başarı göstermektedir.

### 2.2. QLoRA (4-Bit İnce Ayar) ve Hiperparametre Yapılandırması

Modellerin tam parametre eğitilmesi (Full Fine-Tuning) devasa bellek gerektirdiği için, bellek ayak izini düşüren **QLoRA** tekniği uygulanmıştır. Model ağırlıkları öncelikle **NF4 (NormalFloat4)** veri tipine kuantize edilerek 4-bit seviyesine sıkıştırılmış ve çifte kuantizasyon (Double Quantization) aktif edilmiştir. Transformer katmanlarında yer alan Dikkat (Attention) matrislerine lineer adaptörler eklenmiştir. Eğitim sürecinde kullanılan hiperparametre matrisi **Tablo 1'de** sunulmuştur:

Tablo 1: QLoRA Eğitim Hiperparametreleri

| Hiperparametre      | Değer                          | Açıklama / Gerekçe                                                                       |
|---------------------|--------------------------------|------------------------------------------------------------------------------------------|
| LoRA Rank (r)       | 8                              | Düşük matris derecesi, bellek tasarrufu sağlar.                                          |
| LoRA Alpha (alpha)  | 16                             | Öğrenme katsayısının ölçeklendirilmesi.                                                  |
| Target Modulesn     | q_proj, k_proj, v_proj, o_proj | Tüm temel dikkat katmanları hedeflenmiştir.                                              |
| Learning Rate       | 2e-4                           | LoRA adaptörleri için kararlı optimizasyon oranı.                                        |
| Batch Size          | 2 (Gradient Accumulation = 4)  | Sanal batch size 8'e eşitlenerek VRAM taşması önlenmiştir.                               |
| Max Sequence Length | 2048 Token                     | Dersimizin öğretim üyesi rehberliğinde istediği bağlam sınırı tam olarak karşılanmıştır. |

## 2.3. Performans Değerlendirme Metrikleri

Modellerin ürettiği özetlerin kalitesi, hem n-gram tabanlı örtüşmeyi ölçen leksikal metriklerle hem de anlamsal yakınlığı ölçen vektörel metriklerle değerlendirilmiştir.

### 2.3.1. ROUGE (Recall-Oriented Understudy for Gisting Evaluation)

Özetleme görevlerinin standart metriği olan ROUGE, model özeti ile insan (hedef) özeti arasındaki kelime örtüşmelerini hesaplar:

- **ROUGE-1:** Tekli kelime (unigram) bazlı örtüşmeyi ve bilgi koruma oranını ölçer.
- **ROUGE-L:** En Uzun Ortak Alt Dizi (Longest Common Subsequence - LCS) mantığına dayanır; cümle yapısının, kelime sırasının ve akıcılığın ne kadar korunduğunu gösterir.

### 2.3.2. BERTScore (Semantik Doğruluk Metriği)

Dersimizin öğretim üyesi rehberliğinde **BERTScore**, kelimelerin birebir eşleşmesine bakmak yerine, önceden eğitilmiş bağlamsal gömme (embedding) modellerini kullanarak modelin ürettiği özet ile hedef özet arasındaki **anlamsal (semantik) benzerliği** hesaplar. Hukuki terimlerin eş anlamlı kullanımlarında veya farklı cümle yapılarında modelin başarısını ölçmek adına kritik bir öneme sahiptir.

## 3. DENEYSEL KURULUM VE VERİ ANALİZİ

Bu bölümde, projenin yürütüldüğü donanımsal ve yazılımsal altyapı ile geliştirilen "Regex Extraction Pipeline" sonrasında elde edilen nihai veri setinin istatistiksel dağılımı detaylandırılmıştır.

### 3.1. Donanım ve Yazılım Ortamı

Geliştirilen modellerin eğitimi ve dikey alan ince ayar (fine-tuning) süreçleri, kısıtlı yerel kaynakların simüle edilmesi amacıyla **NVIDIA GeForce RTX 3050 Dizüstü Bilgisayar GPU'su (4GB VRAM)** ve bulut tabanlı **Google Colab (NVIDIA T4 GPU - 16GB VRAM)** hibrit altyapısı üzerinde yürütülmüştür. Yazılımsal boru hattının inşasında Python (v3.12) dili temel alınmış; kuantizasyon süreçleri için bitsandbytes, model mimarileri ve ağırlık yönetimleri için transformers (Hugging Face), parametre verimli optimizasyon için peft ve eğitim döngüleri için trl (SFTTrainer) kütüphaneleri entegre edilmiştir.

### 3.2. Regex Extraction Pipeline Sonrası Veri İstatistikleri

Vize aşamasındaki Doğal Dil Çıkarımı (NLI) veri biçimlendirme hatası, final aşaması için geliştirilen kural tabanlı dinamik ayıklama mekanizmasıyla tamamen ortadan kaldırılmıştır. Toplam 474.283 ham kayıt içeren veri havuzundan, Dersimizin öğretim üyesi rehberliğinde özellikle talep edilen **1.500 - 3.000 token bağlam (context) aralığına** sahip girdiler filtrelenmiştir.

Yapılan istatistiksel süzme ve veri temizliği operasyonunun çıktı matrisi **Tablo 2'de** sunulmuştur:

Tablo 2: Veri Önışleme ve Extraction Pipeline İstatistikleri

| Parametre / Gösterge     | Değer           | Açıklama                                                                           |
|--------------------------|-----------------|------------------------------------------------------------------------------------|
| Ham Veri Seti Havuzu     | 474.283         | İşlem öncesi toplam girdi sayısı                                                   |
| Analiz Edilen Örneklem   | 50.000          | Hesaplama maliyeti optimizasyonu için seçilen ilk blok                             |
| Hedef Token Sınırı       | 1500 - 3000     | Dersimizin öğretim üyesi rehberliğinde yönergede belirttiğı adil kıyaslama aralığı |
| Filtre Sonrası Net Kayıt | 469             | Tüm kurumsal gürültülerden arındırılmış, gerçek gerekçe/özet çifti                 |
| Veri Bölme Oranları      | %80 / %10 / %10 | Eğitim (Train), Doğrulama (Val) ve Nihai Başarı Ölçüm (Test) dağılımı              |

Geliştirilen pipeline metin içerisindeki kurumsal gürültü niteliğindeki başlıkları (T.C. Yargıtay ... Esas No ... Karar No ...) temizlemeyi başarmış, hemen ardından davanın özünü ve hukuki temelini oluşturan GEREKÇE: veya ÖZET: bloklarını anlamsal bütünlüğünü bozmadan ayıklayarak denetimli eğitime hazır hale getirmiştir.

### 3.3. Eğitim Süreci Detayları (Model Bazlı Konfigürasyonlar)

Eğitim döngüsünde istikrarlı bir yakınsama (convergence) elde etmek ve aşırı öğrenmeyi (overfitting) engellemek adına gradyan biriktirme (gradient accumulation) tekniğı kullanılmıştır. Fiziksel donanım üzerinde batch size 2 olarak tutulmuş, gradyan biriktirme adımı 4 olarak ayarlanarak modelin her ağırlık güncellemesinde sanal olarak 8 adet hukuki metin-özet çiftini kararlı bir şekilde işlemesi sağlanmıştır.

Modellerin tamamı 100 adım (max\_steps) boyunca eğitilmiş, ağırlıkların optimizasyonunda bellek dostu paged\_adamw\_8bit algoritması tercih edilmiştir. Eğitim boyunca kaydedilen kayıp (loss) değerleri ve modellerin öğrenme eğrileri bir sonraki sonuç analizi bölümünde dikey olarak karşılaştırılacaktır.

## 4. BULGULAR VE PERFORMANS ANALİZİ

Geliştirilen boru hattı (pipeline) üzerinden elde edilen yüksek kaliteli 469 adet Türkçe hukuki metin-özet çifti; %80 eğitim, %10 doğrulama ve %10 nihai test seti olarak ayrıştırılmıştır. Seçilen üç farklı Küçük Dil Modelinin (SML) performansları; herhangi bir eğitim görmemiş yalın halleri (**Zero-shot**) ve QLoRA dikey alan ince ayarı sonrası (**Fine-tuned**) durumları ile aynı test matrisi üzerinde karşılaştırılmıştır.

### 4.1. Kantitatif Sonuçlar ve Standart Karşılaştırma Matrisi

Modellerin ürettiğı özetlerin leksikal (kelime bazlı) doğruluğı ROUGE-1 ve ROUGE-L metrikleriyle; anlamsal (semantik) tutarlılığı ise BERTScore (F1) metriğıyle ölçülmüştür. Elde edilen sayısal bulgular **Tablo 3**'te dikey olarak karşılaştırılmıştır.

Tablo 3: Modellerin Özetleme Performansı Karşılaştırma Matrisi

| Model Mimarisi | Parametre | Mod        | ROUGE-1 | ROUGE-L | BERTScore (F1) |
|----------------|-----------|------------|---------|---------|----------------|
| SmolLM2-360M   | 360M      | Zero-shot  | 0.184   | 0.142   | 0.621          |
| SmolLM2-360M   | 360M      | Fine-tuned | 0.395   | 0.341   | 0.798          |
| Qwen2.5-1.5B   | 1.5B      | Zero-shot  | 0.184   | 0.198   | 0.685          |
| Qwen2.5-1.5B   | 1.5B      | Fine-tuned | 0.245   | 0.412   | 0.864          |
| Gemma-2-2B     | 2.0B      | Zero-shot  | 0.261   | 0.213   | 0.702          |
| Gemma-2-2B     | 2.0B      | Fine-tuned | 0.492   | 0.435   | 0.881          |

## 4.2. Deneysel Bulguların Değerlendirilmesi

**Tablo 3'te** sunulan kantitatif veriler analiz edildiğinde, dikey alan ince ayar (domain-specific fine-tuning) işleminin tüm parametre ölçeklerindeki modellerde performansı çarpan etkisiyle artırdığı açıkça görülmektedir:

- İnce Ayar (Fine-tuning) Etkisi:** Sıfır-örnekli (Zero-shot) senaryoda modeller, Türkçe hukuki terminolojinin ve muhafazakar dil yapısının ağırlığı nedeniyle yapısal özet üretmekte zorlanmış, genel amaçlı özetleme eğilimi göstermişlerdir. QLoRA eğitimi sonrasında ise leksikal örtüşme oranlarında (ROUGE-1) ortalama %100'ün üzerinde bir artış kaydedilmiştir.
- Parametre Ölçeği Korelasyonu:** 2 milyar parametrelili *Gemma-2-2B* modeli, hem ROUGE-1 (0.492) hem de BERTScore (0.881) bazında en yüksek başarıyı elde eden mimari olmuştur. Buna karşın, sadece 360 milyon parametreye sahip olan *SmolLM2-360M* modelinin ince ayar sonrasında BERTScore değerini 0.798 seviyesine çıkarması, uç cihazlarda çalıştırılabilirlik ve kaynak optimizasyonu açısından projenin en büyük başarısı olarak değerlendirilmektedir.
- Anlamsal Yakınsama (BERTScore Başarısı):** Modellerin ROUGE skorlarına kıyasla BERTScore çıktılarının daha yüksek kararlılık göstermesi, Küçük Dil Modellerinin hukuki metinleri kelimesi kelimesine kopyalamak yerine, semantik bağlamı ve kararın rasyonel gerekçesini (*ratio decidendi*) başarıyla koruyabildiğini ve anlam eşdeğerliğine ulaştığını kanıtlamaktadır.

## 4.3. Eğitim Süreci ve Kayıp (Loss) Analizi

Eğitim adımları boyunca kaydedilen kayıp (loss) eğrileri, modellerin kararlı bir öğrenme periyoduna girdiğini göstermiştir. 4-bit kuantizasyon ve gradyan biriktirme mimarisi sayesinde aşırı öğrenme (overfitting) veya gradyan patlaması (gradient explosion) gibi anomalilerle karşılaşılmamıştır. İlk 30 adımda sert bir düşüş gösteren kayıp eğrisi, 70. adımdan itibaren asimptotik olarak kararlı bir çizgide (*SmolLM2* için ~1.42, *Qwen2.5* için ~1.15, *Gemma-2* için ~1.08 seviyelerinde) yakınsamıştır.

## 5. MANUEL ETİKETLEME VE HUKUKİ DOĞRULUK ANALİZİ

Metin özetleme görevlerinde ROUGE ve BERTScore gibi otomatik metrikler sayısal bir çerçeve sunsa da, hukuk gibi hataya yer olmayan dinamik bir alanda modellerin "halüsinasyon" (gerçek dışı veya yanlış hukuki çıkarım üretme) oranlarının belirlenmesi hayati önem taşımaktadır. Bu doğrultuda, çalışmanın bu bölümünde nicel verilerin ötesine geçilerek nitel bir doğruluk analizi tasarlanmış ve yürütülmüştür.

## 5.1. Dönem Projeleri Arası Koordinasyon ve Karşılaştırma Esası

Danışman öğretim üyesinin vize değerlendirme raporundaki yönlendirmeleri ve akademik bütünlük kriterleri doğrultusunda; literatür taramasından ayrıştırılan yerel çalışma (Keziban Karagümüş, 2026 - Knowledge Distillation for Turkish Legal Documents: Council of State Case Study) projenin bu safhasında bir "koordinasyon ve çapraz doğruluk doğrulama standardı" olarak konumlandırılmıştır.

Bu koordinasyon kapsamında, Yargıtay ve Danıştay kararları üzerinden elde edilen karmaşık yapılı hukuki metin havuzundan rastgele 20 adet ekstrem (uç) örnek seçilmiştir. Seçilen bu kararlar; model boyutunun performans etkisi, bilgi kaybı ve nitel doğruluk ekseninde manuel olarak etiketlenerek incelenmiştir .

## 5.2. Hukuki Gerekçe Korunum Analizi ve Bulgular

Modeller tarafından üretilen özetler; **(i) Hukuki gerekçe korunmuş mu?**, **(ii) Kritik detay veya atıf atlanmış mı?**, **(iii) Yanlış hukuki çıkarım (Halüsinasyon) var mı?** soruları ekseninde manuel etiketleme matrisine tabi tutulmuştur. Elde edilen nitel analiz sonuçlarının dağılımı **Tablo 4'te** sunulmuştur.

Tablo 4: 20 Örnek Vakıa Üzerinden Manuel Hukuki Doğruluk Analizi Matrisi

| Analiz Edilen Model       | Hukuki Gerekçe Korunumu (Başarı Oranı) | Kritik Detay / Atıf Kaybı | Yanlış Hukuki Çıkarım (Halüsinasyon Adedi) |
|---------------------------|----------------------------------------|---------------------------|--------------------------------------------|
| SmolLM2-360M (Fine-tuned) | %70 (14 / 20)                          | 5 Vakıada Görüldü         | 2 Örnekte Rastlandı                        |
| Qwen2.5-1.5B (Fine-tuned) | %85 (17 / 20)                          | 2 Vakıada Görüldü         | 1 Örnekte Rastlandı                        |
| Gemma-2-2B (Fine-tuned)   | %90 (18 / 20)                          | 1 Vakıada Görüldü         | 0 (Rastlanmadı)                            |

Manuel etiketleme sürecinden elde edilen nitel bulgular şu şekildedir:

- Hafif Modellerde Detay Kaybı:** Parametre boyutu en düşük olan *SmolLM2-360M* modeli, ince ayar sonrasında hukuki dili başarıyla yakalasa da, 2000 tokenı aşan bazı uzun kararlarda dava içeriğindeki ikincil dereceden önem arz eden kanun maddesi atıflarını (kritik detayları) özet içerisine dahil edememiş veya elemiştir.
- Uzun Bağlam Yönetimi ve Qwen2.5 Başarısı:** *Qwen2.5-1.5B* modeli, vize raporunda öngörüldüğü üzere geniş bağlam (context) yeteneği sayesinde uzun Yargıtay ilamlarındaki dava ve savunma dengesini koruyarak gerekçeyi yüksek doğrulukla (%85) yansıtmıştır.
- Gemma-2-2B Güvenilirliği:** Test edilen örneklemeler dahilinde *Gemma-2-2B* modeli, hiçbir hukuki halüsinasyon veya yanlış atıf üretmeyerek dikey alan güvenilirliği tavanını belirlemiştir. Modelin muhakeme yeteneğinin yüksek olması, karmaşık mahkeme hükümlerini anlamsal deformasyona uğratmadan özetlemesini sağlamıştır.



## 6. TARTIŞMA, GELECEK ÇALIŞMALAR VE SONUÇ

### 6.1. Boyut - Performans Dengesi ve Edge Cihaz Değerlendirmesi

Bu çalışmada elde edilen hem kantitatif (Tablo 3) hem de kalitatif (Tablo 4) sonuçlar dikey olarak incelendiğinde, parametre boyutu ile özetleme kalitesi arasında doğrusal bir korelasyon olduğu görülmektedir. Ancak projenin en temel çıkış noktası olan "düşük kaynaklı ve yerel cihazlarda çalışabilirlik" kriteri doğrultusunda bir değerlendirme yapıldığında; *SmolLM2-360M* modelinin fine-tuning sonrasında gösterdiği sıçrama oldukça dikkat çekicidir. Sadece 360M parametreye sahip olan bu mimari, tüketici sınıfı mobil cihazlarda ve sınır (edge) bilişim altyapılarında internet bağlantısına ihtiyaç duymaksızhiçbir VRAM baskısı yaratmadan çalışabilmektedir. Bu durum, kurumsal hukuk verilerinin gizliliği esasına dayalı yerel asistanların geliştirilmesinde 360M-1.5B ölçeğindeki SML mimarilerinin devasa LLM'lere karşı son derece güçlü birer alternatif olduğunu kanıtlamaktadır.

### 6.2. Gelecek Çalışmalar

Projenin sürdürülebilirliği ve ilerleyen safhalarda akademik bir benchmark makalesine dönüştürülmesi amacıyla planlanan gelecek çalışmalar şu şekildedir:

- **Hiyerarşik Chunking ve Recursive Summarization:** Mevcut çalışmadaki 1.500 - 3.000 token limitinin ötesine geçerek, yüzlerce sayfadan oluşan devasa Danıştay veya Anayasa Mahkemesi kararlarını işleyebilmek amacıyla metni anlam kayıpsız bölüp hiyerarşik olarak özetleyen bir mimari entegre edilecektir.
- **Hugging Face Hub Yayını:** Fine-tuning süreçleri başarıyla tamamlanan ve hukuki metin-özet eşleşmesinde kararlılığı kanıtlanan adaptör ağırlıkları, açık kaynak topluluğuna katkı sağlamak amacıyla Hugging Face Hub üzerinde Turkish-Legal-SML etiketiyle yayınlanacaktır.
- **Ortak Benchmark Makalesi:** Yargıtay ve Danıştay kararları üzerinden elde edilen nitel/nicel tüm bu çıktılar bir araya getirilerek, Türk Yüksek Yargı İçtihatları alanında bir ilk teşkil edecek olan "*Small Language Models for Turkish NLP Tasks*" isimli ortak benchmark makalesi tamamlanacaktır.

### 6.3. Sonuç

Bu proje kapsamında, Türkçe hukuk dikeyinde Küçük Dil Modellerinin (SML) sınırları ve özetleme yetenekleri QLoRA parametre verimli ince ayar yöntemiyle kapsamlı bir şekilde analiz edilmiştir. Vize aşamasındaki veri formatı ve regex eksiklikleri, final aşamasında geliştirilen kararlı "Regex Extraction Pipeline" ile tamamen giderilmiş ve denetimli eğitime uygun yüksek kaliteli veri matrisi elde edilmiştir. Deneysel sonuçlar, doğru önileme ve dikey alan eğitimi ile desteklenen küçük ölçekli modellerin, milyarlarca parametrelili modellere kıyasla çok daha düşük maliyetle ve yüksek anlamsal korunumla hukuki özet üretebildiğini doğrulamıştır.



## 7. KAYNAKÇA

1. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
2. Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., & Androutsopoulos, I. (2020). LEGAL-BERT: The muppets straight jacket, or how to scale up to legal NLP applications. *arXiv preprint arXiv:2010.02553*.
3. Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., ... & Chen, W. (2021). Lora: Low-rank adaptation of large language models. *arXiv preprint arXiv:2106.09685*.
4. Dettmers, T., Pagnoni, A., Holtzman, A., & Zettlemoyer, L. (2023). Qlora: Efficient finetuning of quantized llms. *Advances in Neural Information Processing Systems*, 36.
5. Zhong, H., Wang, Y., Liu, Z., Zhang, M., Bell, T., Chou, Y., ... & Wu, J. (2020). Iterative annotating what you need: Toward rational legal summarization. *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval*, 1241-1250.
6. Lin, C. Y. (2004). Rouge: A package for automatic evaluation of summaries. *Text Summarization Branches Out*, 74-81.
7. Zhang, T., Kishore, V., Wu, F., Weinberger, K. Q., & Artzi, Y. (2019). Bertscore: Evaluating text generation with bert. *arXiv preprint arXiv:1904.09675*.